StatDat Projekt

Christoffer Teorell

September 2026

1 Del A. Ett land, två grupper

1.1 A1. Förhandskontroll och förregistrering

1.2 A2. Frekventistisk utgångspunkt

Vi har $X_j|\Theta_j = \theta_j \sim \text{Bin}(n_j, \theta_j)$ och samma för k. Vi beräknade att

$$\begin{cases} \hat{\theta}_{j,\text{obs}} = 0.194 \\ n_j = 325 \\ \hat{\theta}_{k,\text{obs}} = 0.24 \\ n_k = 546 \end{cases}$$

1.2.1 ML-Skattning av delta

Vi antar $X_j|\Theta_j = \theta_j \perp\!\!\!\perp X_k|\Theta_k = \theta_k$

Vi vill visa att vi har följande ML-skattning

$$\hat{\delta} = \hat{\theta}_j - \hat{\theta}_k = \frac{X_j}{n_j} - \frac{X_k}{n_k}$$

Vi börjar med att visa ML-skattningen för p för en $\text{Bin}(n, p)$ fördelning. Vi har

$$\begin{aligned} & L(x|p) = \binom{n}{x} p^x (1-p)^{n-x} \\ \implies & \log L(x|p) = \log \binom{n}{x} + x \log p + (n-x) \log(1-p) \\ \implies & \frac{\partial}{\partial p} \log L(x|p) = \frac{x}{p} - \frac{n-x}{1-p} = 0 \\ \implies & \frac{x}{p} = \frac{n-x}{1-p} \implies x - px = np - px \implies p = \frac{x}{n} \end{aligned}$$

Eftersom vi har oberoende kan vi skriva vår simultana täthetsfunktionen som

$$f_{X_j,X_k|\Theta_j,\Theta_k}(x_j,x_k|\theta_j,\theta_k) = f_{X_j|\Theta_j}(x_j|\theta_j)f_{X_k|\Theta_k}(x_k|\theta_k)$$

därmed får vi följande log-likelihood funktion

$$\log L(x_j,x_k|\theta_j,\theta_k) = \log f_{X_j|\Theta_j}(x_j|\theta_j) + \log f_{X_k|\Theta_k}(x_k|\theta_k)$$

Vilket enligt ovan ger ML-skattningen för $[\theta_j,\theta_k]^T$

$$\begin{cases} \hat{\theta}_j = \frac{X_j}{n_j} \\ \hat{\theta}_k = \frac{X_k}{n_k} \end{cases}$$

Vi kan nu använda invariansegenskapen av ML-skattningar. Låt $\tau : \mathbb{R}^2 \to \mathbb{R}^2$ vara definierad av

$$\tau(a,b) = (a-b,b)$$

Vi noterar att τ är bijektiv med invers $\tau^{-1}(a,b) = (a+b,b)$. Då ger invariansegenskapen att ML-skattningen av $\tau([\theta_j,\theta_k])$ är

$$\tau(\hat{\theta}_j,\hat{\theta}_k) = (\hat{\theta}_j - \hat{\theta}_k, \hat{\theta}_k) = (\hat{\delta},\hat{\theta}_k)$$

Vi kan läsa av första raden och ser att ML-skattningen av $\theta_j - \theta_k$ ges av $\hat{\delta} = \hat{\theta}_j - \hat{\theta}_k$

Skattningen säger följande: skillnaden mellan andelen positiva svar och andelen negativa svar approximeras av

1.2.2 Väntevärdesriktighet och Cramér-Rao

Vi har skattningen

$$\hat{\delta} = \frac{1}{n_j}X_j - \frac{1}{n_k}X_k$$

Väntevärdet av skattningen ges av

$$\begin{aligned} E[\hat{\delta}] &= \frac{1}{n_j}E[X_j] - \frac{1}{n_k}E[X_k] \\ &= \frac{1}{n_j}n_j\theta_j - \frac{1}{n_k}n_k\theta_k \\ &= \theta_j - \theta_k \end{aligned}$$

Vi hittar nu variansen

$$\begin{aligned} \mathrm{Var}[\hat{\delta}] &= \frac{1}{n_j^2}\mathrm{Var}[X_j] + \frac{1}{n_k^2}\mathrm{Var}[X_k] \\ &= \frac{1}{n_j^2}\big(n_j\theta_j(1-\theta_j)\big) + \frac{1}{n_k^2}\big(n_k\theta_k(1-\theta_k)\big) \\ &= \frac{\theta_j(1-\theta_j)}{n_j} + \frac{\theta_k(1-\theta_k)}{n_k} \end{aligned}$$

Cramér Rao säger att

$$\text{Var}[W[X]] \geq \nabla g^T I^{-1}(\theta_j, \theta_k) \nabla g$$

Vi har

$$g(\theta_j, \theta_k) = \delta = \theta_j - \theta_k \implies \nabla g = (1, -1)$$
$$W[X] = \hat{\delta} = \frac{X_j}{n_j} + \frac{X_k}{n_k}$$

Fischer informationen ges av följande matris

$$I(\theta_j, \theta_k) = \begin{pmatrix} E\left[\left(\frac{\partial}{\partial \theta_j} \log L\right)^2\right] & E\left[\frac{\partial}{\partial \theta_j}(\log L)\frac{\partial}{\partial \theta_k}(\log L)\right] \\ E\left[\frac{\partial}{\partial \theta_k}(\log L)\frac{\partial}{\partial \theta_j}(\log L)\right] & E\left[\left(\frac{\partial}{\partial \theta_k} \log L\right)^2\right] \end{pmatrix}$$

Vi kan även skriva det i termer av andraderivator och får då

$$I(\theta_j, \theta_k) = -\begin{pmatrix} E\left[\frac{\partial^2}{\partial \theta_j^2} \log L\right] & E\left[\frac{\partial^2}{\partial \theta_j \partial \theta_k} \log L\right] \\ E\left[\frac{\partial^2}{\partial \theta_k \partial \theta_j} \log L\right] & E\left[\frac{\partial^2}{\partial \theta_k^2} \log L\right] \end{pmatrix}$$

Vi har

$$\frac{\partial}{\partial \theta_j} \log L = \frac{X_j}{\theta_j} - \frac{n_j - X_j}{1 - \theta_j}$$
$$\implies \frac{\partial^2}{\partial \theta_j^2} \log L = -\frac{X_j}{\theta_j^2} - \frac{n_j - X_j}{(1 - \theta_j)^2}$$

Alltså får vi följande väntevärde

$$E\left[\frac{\partial^2}{\partial \theta_j^2} \log L\right] = -\frac{1}{\theta_j^2} E[X_j] - \frac{n_j}{(1 - \theta_j)^2} + \frac{1}{(1 - \theta_j)^2} E[X_j]$$

För fixt θ_j har vi att $E[X_j | \Theta_j = \theta_j] = n_j \theta_j$. Insättning ger

$$\begin{aligned} E\left[\frac{\partial^2}{\partial \theta_j^2} \log L\right] &= -\frac{n_j \theta_j}{\theta_j^2} - \frac{n_j}{(1 - \theta_j)^2} + \frac{n_j \theta_j}{(1 - \theta_j)^2} \\ &= -\frac{n_j}{\theta_j} - \frac{n_j(1 - \theta_j)}{(1 - \theta_j)^2} \\ &= -\left(\frac{n_j}{\theta_j} + \frac{n_j}{(1 - \theta_j)}\right) = \frac{-n_j}{\theta_j(1 - \theta_j)} \end{aligned}$$

Detta ger även att

$$E\left[\frac{\partial^2}{\partial\theta_k^2}\log L\right] = \frac{-n_k}{\theta_k(1-\theta_k)}$$

Vidare blir blandtermerna lika med 0 eftersom $\frac{\partial}{\partial\theta_j}\log L$ inte innehåller θ_k och vice versa

Alltså får vi följande Fisher-informationsmatris

$$I(\theta_j,\theta_k) = -\begin{pmatrix} \frac{-n_j}{\theta_j(1-\theta_j)} & 0 \\ 0 & \frac{-n_k}{\theta_k(1-\theta_k)} \end{pmatrix}$$

Alltså har vi följande invers:

$$I^{-1}(\theta_j,\theta_k) = \begin{pmatrix} \frac{\theta_j(1-\theta_j)}{n_j} & 0 \\ 0 & \frac{\theta_k(1-\theta_k)}{n_k} \end{pmatrix}$$

Alltså har vi att den undre gränsen från Cramér Raos sats ges av

$$\nabla g^T I^{-1}(\theta_j,\theta_k)\nabla g = \frac{\theta_j(1-\theta_j)}{n_j} + \frac{\theta_k(1-\theta_k)}{n_k}$$

Vi ser nu att detta är precis lika med $\mathrm{Var}[\delta]$. Därmed uppfyller vi den lägre gränsen för Cramér Rao

1.3 A3. Konjugerade aposteriorifördelningar

1.3.1 Härledning av aposteriorifördelning

Vi har följande uppställning

$$\begin{cases} X|\Theta = \theta \sim \mathrm{Bin}(n,\theta) \\ \Theta \sim \mathrm{Beta}(\alpha,\beta) \end{cases}$$

Vi vill hitta aposteriorifördelningen som ges av

$$f_{\Theta|X}(\theta|x) = \frac{f_{X|\Theta}(x|\theta)f_\Theta(\theta)}{f_X(x)}$$

Vi vet att

$$f_X(x) = \int_{\nleqslant} f_{X|\Theta}(x|\theta)f_\Theta(\theta)d\theta \in \mathbb{R}$$

Eftersom $f_X(x) \in \mathbb{R}$ kan vi ignorera den och betrakta följande proportionalitetspåstående istället

$$f_{\Theta|X}(\theta|x) \propto f_{X|\Theta}f_\Theta(\theta)$$

Vi vet att

$$\begin{cases} f_{X|\Theta}(x|\theta) = \binom{n}{x}\theta^x(1-\theta)^{n-x} \\ f_\Theta(\theta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\theta^{\alpha-1}(1-\theta)^{\beta-1} \end{cases}$$

Då får vi att

$$f_{\Theta|X}(\theta|x) \propto \binom{n}{x}\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}\theta^{(\alpha+x)-1}(1-\theta)^{(n+\beta-x)-1}$$

Vi kan ignorera konstanten och identifiera detta med en Beta$(\alpha+x, n+\beta-x)$ fördelning. Vi kan nu sätta $\alpha = \beta = 0$ och får

$$\Theta|X \sim \text{Beta}(x, n-x)$$

Därmed har vi följande aposterioriförderlningar för vårt Θ_j, Θ_k

$$\begin{cases} \Theta_j|X_j \sim \text{Beta}(x_j, n_j - x_j) \\ \Theta_k|X_k \sim \text{Beta}(x_k, n_k - x_k) \end{cases}$$

1.3.2 Simulering av Delta

Free, svara frpgan om varför

1.3.3 Bayesianskt hypotestest

Vi formar hypotesen

$$H_0 : \theta_j \leq \theta_k \text{ mot } H_1 : \theta_j > \theta_k$$

med förlustfunktionen

$$L($$

ssss